

2026 04 09
발표 자료


광운대학교 로봇학과
FAIR Lab

김한서

이번 주 진행사항


- VPNet
 - 아이디어 및 실험
- PhaseFormer
 - 논문 리뷰
 - 재현 실험

Remind




- Autoencoder, decoder를 통해 과거 데이터를 재구성하는 과정을 거치게 되고, 이 과정에서 디코더가 시계열의 데이터 분포 학습, 이후 예측 과정에서 예측값이 비정상적인 형태를 띠는 것을 방지
- Channelize 과정에서 기존 시계열 구조에서 이미지 구조로 차원 변경 후, DepthwiseConv 연산을 통해 변수 간 상관관계 추출
- Pointwise-MLP로 각 임베딩 차원의 특징값을 Mixing하여 고차원 임베딩 벡터 생성

MoE (Mixture of Experts) 설명



- 토큰을 Router에 입력하여 Router 내부의 Gate를 통과하여 각 가중치로 변환, 이후 Expert인 각 FFN에도 동일하게 토큰을 입력하여 Hidden Representation으로 변환
- 가중치와 Hidden Representation을 각각 곱한 뒤 모두 더하여 최종 벡터값 생성

아이디어



MoE Layer

- Predictor와 동일한 입력을 받아서 Gate를 통해 가중치 생성 및 Expert로 Hidden Representation 생성 각각을 곱한 최종 MoE 값과 Predictor 출력값을 더하여 사용

$$\widehat{Z}_{future} = f_\theta(X) + \alpha \cdot \Lambda \odot \sum_{i=1}^2 G_i(X) E_i(X)$$

실험 세팅

- 사용한 모델: VPNet
- 재현 실험 데이터셋: ETTh1, ETTm1, Weather

Experiment	ETTh1
Learning rate	10^{-4}
Epoch	100
Batch size	32
Loss function	MAE Loss
Seq_len	96
Pred_len	96/192/336/720
Layers	2
Patch Size	8
Hidden_len	96
Middle_len	512

VPNet 재현 실험 (ETTh1)

	ETTh1 Reproduction		ETTh1 + MoE	
Pred len	MSE	MAE	MSE	MAE
96	0.374	0.386	<u>0.375</u>	0.386
192	0.428	0.418	0.428	0.418
336	0.464	0.439	<u>0.468</u>	<u>0.440</u>
720	<u>0.471</u>	<u>0.465</u>	0.460	0.459

VPNet 재현 실험 (ETTm1)

	ETTm1 Reproduction		ETTm1 + MoE	
Pred len	MSE	MAE	MSE	MAE
96	0.311	0.341	0.311	0.341
192	<u>0.362</u>	<u>0.371</u>	0.361	0.370
336	0.386	0.390	0.386	0.390
720	0.444	<u>0.425</u>	0.444	0.424

VPNet 재현 실험 (Weather)

	Weather Reproduction		Weather + MoE	
Pred len	MSE	MAE	MSE	MAE
96	<u>0.154</u>	0.192	0.153	<u>0.193</u>
192	0.202	<u>0.240</u>	<u>0.203</u>	0.239
336	0.259	0.281	<u>0.262</u>	<u>0.284</u>
720	0.336	0.335	<u>0.339</u>	<u>0.340</u>

이후 계획

- DepthwiseConv 또는 Pointwise-MLP에 아이디어 추가
- 논문 리뷰

PHASEFORMER: FROM PATCHES TO PHASES FOR EFFICIENT AND EFFECTIVE TIME SERIES FORECASTING

Yiming Niu^{1,*}, Jinliang Deng^{1,2,*}, Yongxin Tong^{1,†}


¹ State Key Laboratory of Complex & Critical Software Environment, Beihang University
{yimingniu, yxtong}@buaa.edu.cn

² Research Institute of Trustworthy Autonomous Systems, SUSTech
jinliangdeng9588@gmail.com


- 인용 수: 1회 (Google Scholar, 2026-04-08)
- Published at ICLR 2026
- 링크: <https://openreview.net/pdf?id=Lk9SqMQzhX>

PhaseFormer

Background



(a) Patch Token vs. Phase Token.




(b) Model Accuracy and Efficiency Comparison.

- 인접 데이터를 묶는 기존 Patch 방식은 데이터의 변동성이 커서 모델이 비교적 커지게 됨
- PhaseFormer는 각 주기(Period)에서 정확히 같은 위치(Phase)에 있는 데이터만 연결한 방식, 이를 통해 기존 모델들보다 파라미터 수 절감 및 예측 성능이 향상되었음

PhaseFormer

모델 구조



- Normalization & Phase Tokenization


- 입력 시계열 데이터 정규화 진행 후, FFT 연산을 통해 데이터의 주기 길이(L_{phase})를 파악
- 이후 Reshape하여 시계열을 주기 단위로 자르고, 2차원 행렬로 차원 변경한 뒤 Permute 연산하여 각 Phase의 값들을 X_{phase} 로 묶어 하나의 토큰으로 사용되게 함

- Embedding

- Phase Token을 임베딩 벡터로 변환한 뒤, Positional Embedding으로 위치 정보 추가

PhaseFormer


모델 구조



- **Phase-to-Router Aggregation**
 - 앞서 생성된 Phase Token을 Key, Value로 사용, Learnable Parameter인 Router R 을 Query로 사용하여 Multi-Head Attention 수행 이후 Context 정보가 담긴 Router H 생성
- **Router-to-Phase Distribution**
 - Router H 를 Key, Value로, Phase Token을 Query로 사용하여 Multi-Head Attention 수행 이 과정을 통해 전역적인 정보가 담긴 Phase Token 생성

PhaseFormer

모델 구조



- **Predictor & Phase De-Tokenization**
 - 앞의 Phase Token이 임베딩 상태이기 때문에 Predictor를 통해 예측값 생성, 2차원 행렬의 예측값이기 때문에 Permute 연산 후 Reshape로 기존 시계열처럼 복원
- **De-normalization**
 - 역정규화 진행하여 원래 스케일로 복원

PhaseFormer

주요 모델 성능 비교

Dataset	Horizon	PhaseFormer		PatchTST		iTransformer		Crossformer		FEDformer		TimeBase		SparseTSF		FITS		TimeMixer		CycleNet		PatchMLP	
		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTh1	96	0.359	0.382	0.377	0.408	0.389	0.421	0.408	0.442	0.485	0.500	0.365	0.387	0.362	0.389	0.380	0.402	0.410	0.441	0.379	0.403	0.417	0.44
	192	0.397	0.404	0.413	0.431	0.424	0.446	0.472	0.496	0.481	0.498	0.403	0.409	0.404	0.412	0.415	0.424	0.448	0.465	0.416	0.425	0.454	0.465
	336	0.425	0.424	0.436	0.444	0.456	0.469	0.480	0.486	0.522	0.521	0.409	0.419	0.435	0.426	0.449	0.460	0.475	0.490	0.447	0.445	0.514	0.503
	720	0.431	0.450	0.455	0.475	0.545	0.532	0.710	0.616	0.604	0.575	0.440	0.448	0.426	0.448	0.433	0.457	0.475	0.500	0.477	0.483	0.548	0.531
ETTh2	96	0.275	0.338	0.276	0.339	0.305	0.361	1.164	0.744	0.401	0.451	0.292	0.350	0.294	0.346	0.271	0.336	0.315	0.380	0.271	0.337	0.324	0.382
	192	0.341	0.376	0.342	0.385	0.405	0.421	1.414	0.830	0.425	0.464	0.339	0.387	0.340	0.377	0.332	0.374	0.383	0.415	0.332	0.38	0.381	0.418
	336	0.369	0.405	0.364	0.405	0.411	0.436	1.220	0.794	0.427	0.471	0.394	0.420	0.360	0.398	0.355	0.396	0.415	0.436	0.362	0.408	0.408	0.44
	720	0.402	0.436	0.395	0.434	0.448	0.470	2.074	1.103	0.462	0.493	0.400	0.448	0.383	0.425	0.378	0.423	0.432	0.471	0.415	0.449	0.454	0.469
ETTm1	96	0.293	0.344	0.298	0.352	0.315	0.369	0.306	0.353	0.406	0.441	0.311	0.351	0.314	0.359	0.313	0.357	0.332	0.384	0.307	0.353	0.319	0.367
	192	0.323	0.361	0.335	0.373	0.349	0.388	0.341	0.385	0.450	0.477	0.338	0.371	0.348	0.376	0.339	0.369	0.362	0.398	0.337	0.371	0.353	0.385
	336	0.358	0.381	0.366	0.389	0.381	0.409	0.383	0.420	0.436	0.466	0.364	0.386	0.368	0.386	0.367	0.385	0.386	0.413	0.364	0.387	0.381	0.401
	720	0.412	0.410	0.420	0.421	0.437	0.439	0.532	0.512	0.462	0.479	0.413	0.414	0.419	0.413	0.417	0.417	0.452	0.457	0.41	0.411	0.436	0.432
ETTm2	96	0.163	0.256	0.165	0.260	0.179	0.274	0.244	0.338	0.339	0.406	0.162	0.256	0.167	0.259	0.166	0.256	0.192	0.285	0.159	0.249	0.186	0.272
	192	0.219	0.293	0.219	0.298	0.239	0.314	0.350	0.412	0.397	0.452	0.218	0.293	0.219	0.297	0.271	0.328	0.307	0.362	0.214	0.289	0.25	0.315
	336	0.269	0.326	0.268	0.333	0.309	0.356	0.400	0.431	0.418	0.452	0.270	0.328	0.271	0.330	0.352	0.380	0.380	0.412	0.268	0.326	0.298	0.347
	720	0.351	0.379	0.352	0.386	0.387	0.407	0.574	0.525	0.451	0.499	0.352	0.380	0.353	0.380	0.352	0.380	0.380	0.412	0.353	0.384	0.38	0.398
Weather	96	0.148	0.195	0.149	0.199	0.159	0.212	0.151	0.210	0.289	0.342	0.146	0.198	0.174	0.231	0.176	0.232	0.163	0.223	0.164	0.220	0.152	0.205
	192	0.193	0.237	0.193	0.243	0.203	0.252	0.220	0.273	0.340	0.403	0.185	0.241	0.216	0.267	0.203	0.256	0.201	0.255	0.209	0.258	0.197	0.247
	336	0.242	0.278	0.240	0.281	0.253	0.291	0.287	0.342	0.370	0.408	0.263	0.281	0.260	0.299	0.261	0.299	0.258	0.300	0.255	0.292	0.248	0.287
	720	0.309	0.332	0.312	0.334	0.317	0.337	0.362	0.393	0.420	0.421	0.314	0.331	0.325	0.345	0.325	0.346	0.329	0.348	0.320	0.338	0.324	0.340
Electricity	96	0.129	0.221	0.141	0.240	0.135	0.233	0.140	0.237	0.226	0.341	0.139	0.231	0.139	0.239	0.147	0.253	0.142	0.247	0.128	0.223	0.141	0.243
	192	0.148	0.238	0.156	0.256	0.155	0.253	0.165	0.259	0.220	0.336	0.153	0.245	0.155	0.250	0.159	0.256	0.164	0.273	0.143	0.237	0.163	0.265
	336	0.165	0.257	0.172	0.267	0.169	0.267	0.190	0.286	0.224	0.337	0.169	0.262	0.171	0.265	0.169	0.270	0.171	0.260	0.159	0.254	0.186	0.290
	720	0.201	0.285	0.208	0.299	0.204	0.301	0.227	0.312	0.271	0.378	0.207	0.294	0.208	0.300	0.214	0.302	0.209	0.313	0.197	0.287	0.221	0.320
Traffic	96	0.361	0.238	0.363	0.250	0.374	0.273	0.512	0.265	0.664	0.431	0.394	0.267	0.389	0.272	0.374	0.273	0.404	0.293	0.381	0.266	0.402	0.302
	192	0.373	0.243	0.382	0.258	0.393	0.283	0.528	0.271	0.613	0.382	0.407	0.270	0.399	0.272	0.393	0.282	0.404	0.292	0.394	0.273	0.419	0.309
	336	0.385	0.248	0.399	0.268	0.409	0.292	0.543	0.281	0.612	0.379	0.417	0.278	0.417	0.279	0.423	0.292	0.425	0.293	0.406	0.279	0.437	0.317
	720	0.428	0.270	0.432	0.289	0.450	0.314	0.598	0.314	0.664	0.410	0.456	0.298	0.449	0.299	0.450	0.314	0.453	0.314	0.441	0.300	0.479	0.342

Ablation Study

Table 2: Cross-Phase Routing layer ablation. Each cell reports MSE, MAE, and FLOPs. Lower is better for all metrics. FLOPs are reported in millions (MFLOPs). The best results are highlighted with **Bold**, and the second-best results with Underlined.

Dataset	PhaseFormer			w/ FullAttention			w/ LinearMixing			w/o Routing		
	MSE	MAE	FLOPs	MSE	MAE	FLOPs	MSE	MAE	FLOPs	MSE	MAE	FLOPs
Weather	0.1503	0.1971	3.119	<u>0.1527</u>	<u>0.2005</u>	3.202	0.1700	0.2226	<u>0.920</u>	0.1907	0.2406	0.783
Electricity	0.1290	0.2209	42.213	<u>0.1295</u>	<u>0.2217</u>	48.951	0.1403	0.2334	<u>14.068</u>	0.1423	0.2365	11.972
Traffic	0.3721	0.2475	113.356	<u>0.3791</u>	<u>0.2513</u>	131.452	0.3842	0.2532	<u>37.776</u>	0.3892	0.2584	32.149

- 기존 Full Attention 방식, LinearMixing, Routing 메커니즘 제거 등과 같이 실험해본 결과, PhaseFormer의 성능이 가장 좋은 것을 확인할 수 있었음

실험 세팅

- 사용한 모델: PhaseFormer
- 재현 실험 데이터셋: ETTh1, ETTm1

Experiment	ETTh1
Learning rate	10^{-3}
Epoch	50
Batch size	256
Loss function	Huber Loss
Seq_len	720
Pred_len	96/192/336/720
Layers	3
Period Len	24
Routers	8~16

재현 실험 (ETTh1)

	ETTh1 Paper		ETTh1 Reproduction	
Pred len	MSE	MAE	MSE	MAE
96	0.359	0.382	0.364	0.386
192	0.397	0.404	0.393	0.410
336	0.425	0.424	0.418	0.424
720	0.431	0.450	0.422	0.444

재현 실험 (ETTm1)

	ETTm1 Paper		ETTm1 Reproduction	
Pred len	MSE	MAE	MSE	MAE
96	0.293	0.344	0.299	0.345
192	0.323	0.361	0.327	0.362
336	0.358	0.381	0.359	0.381
720	0.412	0.410	0.417	0.414

PhaseFormer


이후 계획

- 기존 모델 구조의 Embedding 대신 TCN을 사용해 실험해볼 예정


부록

PhaseFormer

Motivations



(a) Temporal shift comparison across multiple datasets.




(b) PCA for phase tokens on *Traffic*.


- (a)의 경우, 기존 Patch Tokens은 시간이 지남에 따라 분포가 이동하여 예측이 어렵지만, Phase Tokens은 안정적인 예측이 가능해짐
- (b)의 경우, PCA(주성분 분석) 결과, Phase Tokens은 상위 2개의 차원만으로 전체 분산의 90% 이상을 설명 가능함

PhaseFormer


Varying the Number of Routers



(a) Electricity



(b) Traffic



(c) Weather

Figure 5: Effect of varying the number of routers M on forecasting performance on three datasets.

- Router의 개수별 성능 비교, Router 수가 증가함에 따라 예측 오차가 감소하다가 약간 상승함
- 대부분 4~8개의 성능이 가장 좋은 것을 확인